


Relatório para comparação entre as CNNs

1 - Análise dos resultados dos modelos nos conjuntos de teste


A avaliação do desempenho preditivo das arquiteturas no conjunto de testes revelou comportamentos distintos que evidenciam a importância da adequação do modelo à natureza dos dados. No conjunto MNIST, a CNN Customizada alcançou uma expressiva acurácia de 99,39%, superando a arquitetura pré-treinada ResNet18, que obteve 96,53%. Uma análise detalhada por classe demonstra que a CNN Customizada atingiu seu ápice de precisão ao classificar o dígito '3' (99,90% de acerto), enquanto a ResNet18 teve sua melhor performance no dígito '1' (99,30%).

Comparativo de Desempenho por Classe - MNIST



Essa superioridade do modelo construído do zero no MNIST pode ser justificada pela integridade do pré-processamento. A simplicidade da CNN Customizada revelou-se uma vantagem técnica: ao processar as imagens em sua resolução nativa (28x28 pixels) e em canal único de cor, a rede preservou a geometria pura dos dígitos manuscritos. Em contrapartida, o pré-processamento obrigatório exigido pela ResNet18 (escalonamento para 224x224 pixels e triplicação de canais artificiais para simular RGB) introduziu um ruído computacional severo. A interpolação de pixels necessária para ampliar uma imagem tão pequena acabou por distorcer as bordas finas dos números, prejudicando a capacidade da ResNet18 de diferenciar dígitos com traços sobrepostos ou curvas sutis como no caso de maior confusão (5 e 3).

No entanto, o cenário inverteu-se completamente ao analisarmos o conjunto CIFAR-10. Lidando com imagens repletas de ruído de fundo, iluminação variável e texturas orgânicas complexas, a ResNet18 comprovou a robustez do Transfer Learning ao atingir 80,73% de acurácia global, superando os 76,72% da CNN Customizada. É fundamental notar que ambas as arquiteturas convergiram na dificuldade estrutural do dataset: a classe 'cat' configurou-se como o maior desafio preditivo para os dois modelos. Esse fenômeno é esperado, visto que felinos apresentam altíssima variância intra-classe (diferentes raças, poses, cores e camuflagens com o ambiente). Por outro lado, as classes em que os modelos obtiveram maior facilidade foram 'frog' para a CNN Customizada, e 'truck' para a ResNet18, possivelmente devido aos padrões de cores mais consistentes dos anfíbios e às linhas rígidas e geométricas dos veículos pesados.



Ao realizarmos um comparativo global entre os domínios de dados, a média de acertos das arquiteturas no MNIST estabeleceu-se em 97,96%, contra apenas 78,72% no CIFAR-10.


Este contraste acentuado corrobora a literatura acadêmica da área de Visão Computacional, demonstrando que a extração de características em ambientes controlados e monocromáticos é um problema majoritariamente resolvido, enquanto o mapeamento semântico de objetos em contextos reais continua a exigir modelos com alta profundidade e mecanismos sofisticados de propagação de gradiente.

2 - Análise dos features maps dos modelos


Para compreender o nível de abstração visual alcançado pelas arquiteturas, procedeu-se com a extração e análise dos Feature Maps gerados pelas camadas convolucionais. O experimento selecionou amostras representativas de ambos os conjuntos de dados: os dígitos '0', '4' e '8' para o domínio do MNIST, e as classes 'airplane', 'cat' e 'ship' para o domínio do CIFAR-10.

Ao avaliar as ativações referentes ao conjunto MNIST, constatou-se uma disparidade visual notável entre os mapas gerados pelas duas arquiteturas. Nas primeiras camadas convolucionais, a CNN Customizada demonstrou extrair características de forma muito mais nítida e eficiente, comportando-se como um excelente detector de bordas e isolando o formato geométrico dos números com clareza. Em contrapartida, as ativações iniciais da ResNet18 apresentaram-se visualmente menos informativas mostrando apenas uma separação do em relação ao fundo mas sem focar em bordas. Esse prejuízo na abstração inicial da ResNet18 é uma consequência direta do pré-processamento exigido pela arquitetura: o redimensionamento drástico da imagem e a replicação artificial de um único canal em tons de cinza para três canais de cor (RGB) diluíram a pureza espacial dos dados originais. Como resultado, os filtros da rede pré-treinada tiveram maior dificuldade inicial para capturar os traços simples e definidos dos dígitos em comparação ao modelo customizado, que operou de forma otimizada na resolução nativa.


Ativações - Camada Convolutacional 1




Ativações ResNet18 - conv1 (Convolução Inicial)



Ativações - Camada Convolutacional 2




Ativações ResNet18 - layer1 (1º Bloco Residual)




Entretanto, a análise visual das ativações do conjunto CIFAR-10 revelou uma inversão nesse comportamento. Inicialmente, poderia-se presumir que o redimensionamento drástico das imagens originais (de 32x32 pixels para a entrada de 224x224 da ResNet18) prejudicaria a rede da mesma forma. Contudo, os mapas de características demonstraram o oposto. As ativações da ResNet18 para as classes complexas, como 'airplane' e 'ship', mostraram-se expressivamente mais nítidas e informativas do que as geradas pela CNN Customizada. Esse fenômeno ocorreu porque a ampliação artificial da grade de resolução permitiu que os filtros convolucionais robustos da ResNet18 tivessem uma área espacial maior para atuar. Consequentemente, o modelo pré-treinado conseguiu abstrair as texturas e delinear o contorno dos objetos coloridos com muito mais precisão, isolando ativamente a figura principal do seu pano de fundo ruidoso. Em contrapartida, a CNN Customizada, limitada pela baixa resolução nativa de 32x32 pixels do CIFAR-10, gerou mapas de ativação muito mais turvos e aglomerados, evidenciando a dificuldade de uma rede construída do zero em destrinchar detalhes complexos quando confinada a uma grade espacial estritamente reduzida.


Ativações - Camada Convolutacional 1




Ativações ResNet18 - conv1 (Convolução Inicial)



Ativações - Camada Convolutacional 2



Ativações ResNet18 - layer1 (1º Bloco Residual)



3 - Conclusão

Este estudo comprovou empiricamente que o uso de Transfer Learning com arquiteturas profundas não é uma solução unilateral ou absoluta para qualquer cenário de classificação. Conforme demonstrado pelos resultados no dataset MNIST, a aplicação cega de modelos colossais em dados simples pode resultar em perdas de desempenho devido a distorções no redimensionamento. Contudo, em contextos de alta complexidade visual (CIFAR-10), as conexões residuais e o aprendizado prévio da ResNet18 garantem uma supremacia inegável.

Para trabalhos futuros visando aprimorar o desempenho preditivo da CNN Customizada, sugere-se uma expansão metodológica no algoritmo de Random Search. Considerando que restrições computacionais limitaram a busca a apenas 10 configurações arquiteturais treinadas por 20 épocas, a execução de um volume consideravelmente maior de explorações (entre 50 e 100 iterações), aliada a um limite estendido de épocas de treinamento, permitiria ao modelo explorar melhor a superfície de erro em busca de mínimos globais. Além disso, a inclusão de técnicas de regularização contemporâneas no espaço de busca, notadamente a aplicação de Batch Normalization entre as camadas convolucionais, apresenta forte potencial para acelerar a convergência e elevar a capacidade de generalização da rede customizada a patamares estatisticamente comparáveis aos de modelos do estado da arte.